




Rapport de TP : Gestion des fichiers dans Hadoop

Ce rapport présente les travaux pratiques réalisés par **Jebrou Mohammed** et **Farid Hajar** dans le cadre du module **Big Data** de l'Université Internationale Ibn Tofail Kénitra pour l'année universitaire 2025/2026, sous la supervision de **Pr. Hajar Filali**.

Objectifs du TP

Ce Travail Pratique (TP2) est spécifiquement conçu pour initier et renforcer la compréhension des apprenants concernant le fonctionnement et la manipulation du **Système de Fichiers Distribué Hadoop (HDFS)**.

Les objectifs principaux couverts par cette session sont les suivants :

- **Démarrage et arrêt des services Hadoop** : Maîtriser le lancement et l'arrêt des processus nécessaires au bon fonctionnement de l'écosystème Hadoop.
- **Gestion de la structure de fichiers HDFS** : Apprendre à créer, visualiser et naviguer dans l'arborescence des répertoires au sein du HDFS.
- **Manipulation de fichiers** : Utiliser les commandes spécifiques de l'interface de ligne de commande Hadoop (CLI) pour les opérations courantes sur les fichiers (création, suppression, déplacement, copie, etc.).
- **Interaction entre systèmes de fichiers** : Réaliser des transferts de fichiers entre le système de fichiers local et le HDFS (upload et download).
- **Inspection des données** : Visualiser le contenu des fichiers stockés dans le HDFS.

Ces manipulations constituent la base essentielle pour la gestion efficace des données massives dans un environnement distribué.


Déroulement du TP

Étape 1 : Démarrage de l'Environnement Hadoop

Le Travail Pratique a débuté par la mise en route des services essentiels de l'écosystème Hadoop pour rendre le HDFS opérationnel et accessible. Cette étape est cruciale pour toute interaction ultérieure avec le système de fichiers distribué.

1.1. Démarrage des Daemons Hadoop

Nous avons utilisé les scripts de démarrage fournis par l'installation Hadoop pour lancer tous les processus nécessaires (NameNode, DataNode, Secondary NameNode, ResourceManager et NodeManager, si l'environnement YARN était également configuré).

A terminal window titled 'mohammed@ROG-Strix:~' with standard window controls. It shows the execution of two scripts: 'start-dfs.sh' and 'start-yarn.sh'. The first script starts the NameNode, DataNode, and Secondary NameNode daemons, each with its respective logging path. The second script starts the YARN daemons: ResourceManager and NodeManager, also with their logging paths. The prompt at the bottom is '~' with a refresh icon to its left.

```
> start-dfs.sh
Starting namenodes on [localhost]
localhost: starting namenode, logging to /home/mohammed/hadoop-2.7.1/logs/hadoop-mohammed-namenode-ROG-Strix.out
localhost: starting datanode, logging to /home/mohammed/hadoop-2.7.1/logs/hadoop-mohammed-datanode-ROG-Strix.out
Starting secondary namenodes [0.0.0.0]
0.0.0.0: starting secondarynamenode, logging to /home/mohammed/hadoop-2.7.1/logs/hadoop-mohammed-secondarynamenode-ROG-Strix.out
> start-yarn.sh
starting yarn daemons
starting resourcemanager, logging to /home/mohammed/hadoop-2.7.1/logs/yarn-mohammed-resourcemanager-ROG-Strix.out
localhost: starting nodemanager, logging to /home/mohammed/hadoop-2.7.1/logs/yarn-mohammed-nodemanager-ROG-Strix.out
~
```

1.2. Vérification du Statut des Services

Afin de confirmer que tous les services sont correctement initialisés et en cours d'exécution, nous avons vérifié les processus Java actifs sur le système à l'aide de la commande `jps` (Java Virtual Machine Process Status Tool) :

```
mohammed@ROG-Strix:~  
> jps  
37158 SecondaryNameNode  
36921 DataNode  
43209 Jps  
37804 NodeManager  
36718 NameNode  
37486 ResourceManager  
~
```

2. Création de l'arborescence dans le HDFS

Après le démarrage d'Hadoop, l'étape consiste à créer la structure de répertoires nécessaire au TP directement dans le HDFS. Cela est réalisé en utilisant les commandes Hadoop pour créer les répertoires principaux ainsi que tous les sous-répertoires requis pour organiser les données d'entrée (**Cours** et **TPs**) sous les catégories principales (**JAVA** et **CPP**) à l'intérieur du répertoire racine du projet (**/BDDC**).

```
mohammed@ROG-Strix:~  
> hdfs dfs -mkdir -p /BDDC/{JAVA,CPP}/{Cours,TPs}  
~
```

2.1. Vérification de la structure et des répertoires créés

Après la création de la structure de répertoires, une étape de vérification est essentielle pour s'assurer que l'arborescence désirée a été correctement mise en place dans le HDFS.

Nous avons utilisé la commande de listage récursive pour visualiser l'intégralité de la structure créée sous le répertoire racine **/BDDC** : `hadoop fs -ls -R /BDDC`

```
mohammed@ROG-Strix:~  
> hdfs dfs -mkdir -p /BDDC/{JAVA,CPP}/{Cours,TPs}  
> hdfs dfs -ls -R /BDDC  
drwxr-xr-x - mohammed supergroup 0 2026-03-18 21:47 /BDDC/CPP  
drwxr-xr-x - mohammed supergroup 0 2026-03-18 21:47 /BDDC/CPP/Cours  
drwxr-xr-x - mohammed supergroup 0 2026-03-18 21:47 /BDDC/CPP/TPs  
drwxr-xr-x - mohammed supergroup 0 2026-03-18 21:47 /BDDC/JAVA  
drwxr-xr-x - mohammed supergroup 0 2026-03-18 21:47 /BDDC/JAVA/Cours  
drwxr-xr-x - mohammed supergroup 0 2026-03-18 21:47 /BDDC/JAVA/TPs  
🔄🏠~ )
```

3. Création et ajout de contenu dans les fichiers Cours de CPP

Cette étape détaille la création de fichiers locaux contenant des données d'exemple, puis leur transfert vers le répertoire approprié au sein du HDFS.

3.1. Création des fichiers locaux

Trois fichiers d'exemple, nommés **CoursCPP1**, **CoursCPP2**, et **CoursCPP3**, ont été créés sur le système de fichiers local. Chacun de ces fichiers a été initialisé avec un contenu simple correspondant à son nom

```
mohammed@ROG-Strix:~/HADOOP REPO  
> for i in {1..3} ; do echo "CoursCPP$i" > CoursCPP$i ; done  
> ls  
📁 CoursCPP1 📁 CoursCPP2 📁 CoursCPP3  
🔄🏠 HADOOP REPO )
```


3.2. Transfert des fichiers vers HDFS

Une fois les fichiers locaux créés, ils ont été copiés dans le répertoire HDFS dédié aux cours de CPP (**/BDDC/CPP/Cours**)

```
mohammed@ROG-Strix:~/HADOOP REPO  
> hdfs dfs -put CoursCPP{1,2,3} /BDDC/CPP/Cours  
🔄🏠 HADOOP REPO )
```

3.3. Vérification du transfert

Pour confirmer la bonne insertion des fichiers dans HDFS, la commande de listage a été exécutée sur le répertoire cible :




```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -ls /BDDC/ CPP/Cours
Found 3 items
-rw-r--r-- 1 mohammed supergroup 10 2026-03-18 22:08 /BDDC/ CPP/Cours/
CoursCPP1
-rw-r--r-- 1 mohammed supergroup 10 2026-03-18 22:08 /BDDC/ CPP/Cours/
CoursCPP2
-rw-r--r-- 1 mohammed supergroup 10 2026-03-18 22:08 /BDDC/ CPP/Cours/
CoursCPP3
HADOOP REPO >
```

4. Manipulation des fichiers dans HDFS

Cette section explore d'autres manipulations courantes effectuées sur les fichiers au sein du HDFS, notamment la lecture du contenu et la modification de la structure de répertoires.

4.1. Visualisation du contenu des fichiers

Afin de vérifier l'intégrité des données après le transfert, nous avons utilisé la commande `hadoop fs -cat` pour afficher le contenu d'un des fichiers stockés :




```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -cat /BDDC/ CPP/Cours/CoursCPP{1..3}
CoursCPP1
CoursCPP2
CoursCPP3
HADOOP REPO >
```

5. Copie des fichiers CPP vers le répertoire JAVA

Cette étape a démontré la capacité à copier des fichiers d'un répertoire HDFS à un autre, une opération courante pour réutiliser ou dupliquer des données.

L'objectif était de copier les trois fichiers de cours CPP (CoursCPP1, CoursCPP2, CoursCPP3) vers le répertoire dédié aux cours de Java (/BDDC/JAVA/Cours)



```
mohammed@ROG-Strix:~/HADOOP_REPO
> hdfs dfs -cp /BDDC/PHP/Cours/CoursCPP{1,2,3} /BDDC/JAVA/Cours
26/03/18 22:23:26 WARN hdfs.DFSCliant: DFSInputStream has been closed already
26/03/18 22:23:26 WARN hdfs.DFSCliant: DFSInputStream has been closed already
26/03/18 22:23:26 WARN hdfs.DFSCliant: DFSInputStream has been closed already
🔄📁 HADOOP_REPO >
```

5.1. Vérification de la copie

Afin de vérifier la réussite de l'opération de copie, la vérification sera effectuée via l'interface de navigation du système de fichiers DFS, accessible à l'adresse suivante : <http://localhost:50070/explorer.html#/BDDC/JAVA/Cours>.

Browse Directory

/BDDC/JAVA/Cours

Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	mohammed	supergroup	10 B	3/18/2026, 10:23:26 PM	1	128 MB	CoursCPP1
-rw-r--r--	mohammed	supergroup	10 B	3/18/2026, 10:23:26 PM	1	128 MB	CoursCPP2
-rw-r--r--	mohammed	supergroup	10 B	3/18/2026, 10:23:26 PM	1	128 MB	CoursCPP3

6. Suppression et renommage des fichiers dans le répertoire JAVA

Cette étape visait à illustrer la gestion des fichiers au sein de HDFS, spécifiquement la suppression d'un fichier et le renommage des fichiers restants, pour adapter leur nom au nouveau contexte (JAVA).

6.1. Suppression du fichier CoursCPP3

Le fichier **CoursCPP3** (copié précédemment du répertoire CPP) a été supprimé du répertoire **/BDDC/JAVA/Cours**

```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -rm /BDDC/JAVA/Cours/CoursCPP3
26/03/18 22:33:48 INFO fs.TrashPolicyDefault: Namenode trash configuration: Deletion interval = 0 minutes, Empty interval = 0 minutes.
Deleted /BDDC/JAVA/Cours/CoursCPP3
HADOOP REPO
```

6.2. Renommage des fichiers restants

Les deux fichiers restants (**CoursCPP1** et **CoursCPP2**) ont été renommés en **CoursJAVA1** et **CoursJAVA2** respectivement, utilisant la commande de déplacement (**-mv**)

```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -mv /BDDC/JAVA/Cours/CoursCPP2 /BDDC/JAVA/Cours/CoursJAVA2
> hdfs dfs -mv /BDDC/JAVA/Cours/CoursCPP1 /BDDC/JAVA/Cours/CoursJAVA1
HADOOP REPO
```

6.3. Vérification des opérations

Browse Directory

/BDDC/JAVA/Cours							Go!
Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	mohammed	supergroup	10 B	3/18/2026, 10:23:26 PM	1	128 MB	CoursJAVA1
-rw-r--r--	mohammed	supergroup	10 B	3/18/2026, 10:23:26 PM	1	128 MB	CoursJAVA2

7. Création et Transfert des Fichiers de TP

Cette section a pour but d'ajouter des fichiers d'exemple représentant des Travaux Pratiques (TPs) dans les répertoires dédiés au sein du HDFS.

7.1. Création des fichiers locaux pour les TPs

Nous avons créé plusieurs fichiers sur le système de fichiers local qui serviront de TPs pour les cours de CPP et Java

```
mohammed@ROG-Strix:~/HADOOP REPO
> for i in {1..3};do touch TP${i}CPP TP${i}JAVA; done
> ls
TP1CPP TP1JAVA TP2CPP TP2JAVA TP3CPP TP3JAVA
HADOOP REPO
```

8 et 9. Copie des fichiers TPs vers HDFS

Les fichiers locaux ont ensuite été transférés dans leurs répertoires HDFS respectifs, en utilisant une syntaxe d'expansion de chemin pour optimiser les commandes.

Pour les TPs de CPP :

```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -copyFromLocal TP{1..3}CPP /BDDC/ CPP/TPs
HADOOP REPO
```

Browse Directory

/BDDC/ CPP/TPs							Go!
Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:55:16 PM	1	128 MB	TP1CPP
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:55:16 PM	1	128 MB	TP2CPP
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:55:16 PM	1	128 MB	TP3CPP

Pour les TPs de Java :

```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -copyFromLocal TP{1..3}JAVA /BDDC/ JAVA/TPs
HADOOP REPO
```


Browse Directory

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:56:28 PM	1	128 MB	TP1JAVA
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:56:28 PM	1	128 MB	TP2JAVA
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:56:28 PM	1	128 MB	TP3JAVA


10. Affichage récursif du contenu de BDDC

Afin de visualiser la structure finale du répertoire **/BDDC** après toutes les opérations de transfert et de renommage, y compris les fichiers de cours et de TP pour CPP et JAVA

```
mohammed@R06-Strix:~/HADOOP REPO
> hdfs dfs -ls -R /BDDC
drwxr-xr-x  - mohammed supergroup      0 2026-03-18 21:47 /BDDC/ CPP
drwxr-xr-x  - mohammed supergroup      0 2026-03-18 22:08 /BDDC/ CPP/ Cours
-rw-r--r--  1 mohammed supergroup    10 2026-03-18 22:08 /BDDC/ CPP/ Cours/
CoursCPP1
-rw-r--r--  1 mohammed supergroup    10 2026-03-18 22:08 /BDDC/ CPP/ Cours/
CoursCPP2
-rw-r--r--  1 mohammed supergroup    10 2026-03-18 22:08 /BDDC/ CPP/ Cours/
CoursCPP3
drwxr-xr-x  - mohammed supergroup      0 2026-03-18 22:55 /BDDC/ CPP/ TPs
-rw-r--r--  1 mohammed supergroup      0 2026-03-18 22:55 /BDDC/ CPP/ TPs/ TP
1CPP
-rw-r--r--  1 mohammed supergroup      0 2026-03-18 22:55 /BDDC/ CPP/ TPs/ TP
2CPP
-rw-r--r--  1 mohammed supergroup      0 2026-03-18 22:55 /BDDC/ CPP/ TPs/ TP
3CPP
drwxr-xr-x  - mohammed supergroup      0 2026-03-18 22:40 /BDDC/ JAVA
drwxr-xr-x  - mohammed supergroup      0 2026-03-18 22:41 /BDDC/ JAVA/ Cours
-rw-r--r--  1 mohammed supergroup    10 2026-03-18 22:23 /BDDC/ JAVA/ Cours
/ CoursJAVA1
-rw-r--r--  1 mohammed supergroup    10 2026-03-18 22:23 /BDDC/ JAVA/ Cours
/ CoursJAVA2
drwxr-xr-x  - mohammed supergroup      0 2026-03-18 22:56 /BDDC/ JAVA/ TPs
-rw-r--r--  1 mohammed supergroup      0 2026-03-18 22:56 /BDDC/ JAVA/ TPs/ T
```

11. Suppression du fichier TP1CPP

Pour illustrer l'opération de suppression d'un fichier spécifique dans HDFS, le fichier **TP1CPP** a été retiré du répertoire **/BDDC/CPP/TPs**



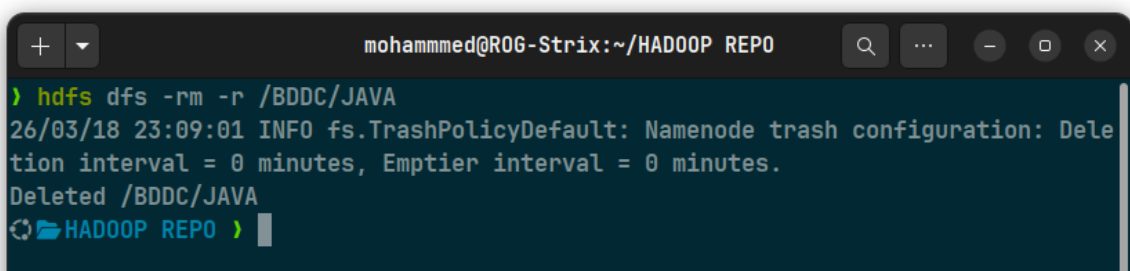
```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -rm /BDDC/CPP/TPs/TP1CPP
26/03/18 23:05:15 INFO fs.TrashPolicyDefault: Namenode trash configuration: Deletion interval = 0 minutes, Empty interval = 0 minutes.
Deleted /BDDC/CPP/TPs/TP1CPP
HADOOP REPO >
```

Browse Directory

/BDDC/CPP/TPs							Go!
Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:55:16 PM	1	128 MB	TP2CPP
-rw-r--r--	mohammed	supergroup	0 B	3/18/2026, 10:55:16 PM	1	128 MB	TP3CPP

12. Suppression du répertoire JAVA et de son contenu

Enfin, pour nettoyer l'espace et démontrer la suppression récursive de répertoires non vides, le répertoire **/BDDC/JAVA** ainsi que tous les fichiers et sous-répertoires qu'il contenait (CoursJAVA1, CoursJAVA2, TP1JAVA, TP2JAVA, TP3JAVA) ont été supprimés



```
mohammed@ROG-Strix:~/HADOOP REPO
> hdfs dfs -rm -r /BDDC/JAVA
26/03/18 23:09:01 INFO fs.TrashPolicyDefault: Namenode trash configuration: Deletion interval = 0 minutes, Empty interval = 0 minutes.
Deleted /BDDC/JAVA
HADOOP REPO >
```

9.1. Vérification de la structure après les suppressions

Browse Directory

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
drwxr-xr-x	mohammed	supergroup	0 B	3/18/2026, 9:47:57 PM	0	0 B	CPP

Conclusion

Ce TP a permis d'acquérir une connaissance pratique et fondamentale de la gestion des fichiers et des répertoires au sein du Système de Fichiers Distribué Hadoop (HDFS). Les manipulations effectuées (démarrage/arrêt, création de structure, upload, visualisation, déplacement, copie et download) sont essentielles pour quiconque souhaite travailler efficacement avec des environnements Big Data. La maîtrise de ces commandes de base est un prérequis indispensable pour les travaux futurs impliquant des traitements distribués de données massives.