

TP 3:Exécution de Hadoop WordCount MapReduce sous Linux

Université / École :

- Université Ibn Tofail, Kénitra

Encadrement pédagogique :

- Pr. Hajar Filali

Rédigé par :

- Mohammed Jebrou
- Hajar Farid

Année universitaire :

- 2025-2026

Introduction au TP : Hadoop WordCount MapReduce

Ce TP présente l'exécution de **WordCount**, un exemple classique de **MapReduce** dans Hadoop, qui permet de compter le nombre d'occurrences de chaque mot dans un fichier texte.

WordCount est un cas fondamental pour comprendre le fonctionnement du traitement distribué dans Hadoop, car il illustre clairement la répartition des tâches entre les phases Map et Reduce


Préparation

1. Téléchargez les fichiers nécessaires

Récupérez les fichiers JAR et d'entrée depuis le dépôt GitHub.

```
wget https://github.com/MuhammadBilalYar/HADOOP-INSTALLATION-ONWINDOW-10/raw/master/MapReduceClient.jar
```

```
wget https://github.com/MuhammadBilalYar/HADOOP-INSTALLATION-ON-WINDOW-10/raw/master/input_file.txt
```




```
mohammed@ROG-Strix:~/HADOOP_REPO  
> ls  
input_file.txt  MapReduceClient.jar  
HADOOP_REPO >
```

2. Placez les fichiers dans votre répertoire personnel

Déplacez les fichiers téléchargés vers votre répertoire home.

```
mv MapReduceClient.jar ~/  
mv input_file.txt ~/
```




```
mohammed@ROG-Strix:~/HADOOP_REPO  
> mv MapReduceClient.jar ~/  
> mv input_file.txt ~/  
HADOOP_REPO >
```

Les Opérations Hadoop

1. Démarrez les services Hadoop

Initialisez les services HDFS et YARN pour préparer l'environnement Hadoop.

```
start-all.sh
```


A terminal window titled 'mohammed@ROG-Strix:~/HADOOP REPO' showing the execution of the 'start-all.sh' script. The script is deprecated and suggests using 'start-dfs.sh' and 'start-yarn.sh'. It shows the process of starting namenodes on localhost, datanodes, secondary namenodes, and yarn daemons (resourcemanager and nodemanager). The process takes 18 seconds to complete.

```
> start-all.sh
This script is Deprecated. Instead use start-dfs.sh and start-yarn.sh
Starting namenodes on [localhost]
localhost: starting namenode, logging to /home/mohammed/hadoop-2.7.1/logs/hadoop-mohammed-namenode-ROG-Strix.out
localhost: starting datanode, logging to /home/mohammed/hadoop-2.7.1/logs/hadoop-mohammed-datanode-ROG-Strix.out
Starting secondary namenodes [0.0.0.0]
0.0.0.0: starting secondarynamenode, logging to /home/mohammed/hadoop-2.7.1/logs/hadoop-mohammed-secondarynamenode-ROG-Strix.out
starting yarn daemons
starting resourcemanager, logging to /home/mohammed/hadoop-2.7.1/logs/yarn-mohammed-resourcemanager-ROG-Strix.out
localhost: starting nodemanager, logging to /home/mohammed/hadoop-2.7.1/logs/yarn-mohammed-nodemanager-ROG-Strix.out
🔄 HADOOP REPO ) took ⌚ 18s
```

2. Vérifiez que les services sont bien démarrés

Confirmez que tous les processus Hadoop sont en cours d'exécution.

```
jps
```

A terminal window titled 'mohammed@ROG-Strix:~/HADOOP REPO' showing the output of the 'jps' command. It lists the following processes and their IDs: 5585 (Jps), 7426 (NodeManager), 7107 (ResourceManager), 6936 (SecondaryNameNode), 6472 (NameNode), 7594 (Jps), and 6716 (DataNode).


```
> jps
5585
7426 NodeManager
7107 ResourceManager
6936 SecondaryNameNode
6472 NameNode
7594 Jps
6716 DataNode
🔄 HADOOP REPO )
```

Les Opérations Hadoop

3. Créez un répertoire d'entrée dans HDFS

Préparez un répertoire dans le système de fichiers distribué pour stocker les données d'entrée.


```
hadoop fs -mkdir /input_dir
```



4. Copiez le fichier texte d'entrée dans HDFS

Transférez le fichier input_file.txt vers le répertoire d'entrée du système distribué.

```
hadoop fs -put ~/input_file.txt /input_dir
```



Les Opérations Hadoop

5. Vérifiez que le fichier input_file.txt est bien présent dans HDFS

Confirmez que le fichier a été correctement transféré vers le répertoire d'entrée.

```
hadoop fs -ls /input_dir/
```




```
mohammed@ROG-Strix:~/HADOOP_REPO
> hadoop fs -ls /input_dir/
Found 1 items
-rw-r--r-- 1 mohammed supergroup 1888 2026-03-25 11:03 /input_dir/input_file.txt
HADOOP_REPO >
```

6. Vérifiez le contenu du fichier copié

Affichez le contenu du fichier pour vérifier que les données sont intactes.

```
hadoop fs -cat /input_dir/input_file.txt
```




```
mohammed@ROG-Strix:~/HADOOP_REPO
> hadoop fs -cat /input_dir/input_file.txt
23 23 27 43 24 25 26 26 26 26 25 26 25
26 27 28 28 28 30 31 31 31 30 30 30 29
31 32 32 32 33 34 35 36 36 34 34 34 34
39 38 39 39 39 41 42 43 40 39 38 38 40
38 39 39 39 39 41 41 41 28 40 39 39 45
23 23 27 43 24 25 26 26 26 26 25 26 25
26 27 28 28 28 30 31 31 31 30 30 30 29
31 32 32 32 33 34 35 36 36 34 34 34 34
39 38 39 39 39 41 42 43 40 39 38 38 40
38 39 39 39 39 41 41 41 28 40 39 39 45
23 23 27 43 24 25 26 26 26 26 25 26 25
26 27 28 28 28 30 31 31 31 30 30 30 29
31 32 32 32 33 34 35 36 36 34 34 34 34
39 38 39 39 39 41 42 43 40 39 38 38 40
38 39 39 39 39 41 41 41 28 40 39 39 45
23 23 27 43 24 25 26 26 26 26 25 26 25
26 27 28 28 28 30 31 31 31 30 30 30 29
```


Les Opérations Hadoop

7. Exécutez MapReduceClient.jar

Lancez le job MapReduce WordCount en spécifiant les répertoires d'entrée et de sortie.

```
hadoop jar ~/MapReduceClient.jar wordcount /input_dir /output_dir
```

A terminal window titled 'mohammed@ROG-Strix:~/HADOOP REPO' showing the execution of a Hadoop WordCount job. The command 'hadoop jar ~/MapReduceClient.jar wordcount /input_dir /output_dir' has been entered. The output consists of several INFO logs from the Configuration, JVM Metrics, FileInputFormat, JobSubmitter, and LocalJobRunner, indicating the job is running successfully on the local filesystem.


```
mohammed@ROG-Strix:~/HADOOP REPO
> hadoop jar ~/MapReduceClient.jar wordcount /input_dir /output_dir
26/03/25 11:11:39 INFO Configuration.deprecation: session.id is deprecated. Instead, use dfs.metrics.session-id
26/03/25 11:11:39 INFO jvm.JvmMetrics: Initializing JVM Metrics with processName=JobTracker, sessionId=
26/03/25 11:11:39 INFO input.FileInputFormat: Total input paths to process : 1
26/03/25 11:11:39 INFO mapreduce.JobSubmitter: number of splits:1
26/03/25 11:11:39 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_local41287041_0001
26/03/25 11:11:39 INFO mapreduce.Job: The url to track the job: http://localhost:8080/
26/03/25 11:11:39 INFO mapreduce.Job: Running job: job_local41287041_0001
26/03/25 11:11:39 INFO mapred.LocalJobRunner: OutputCommitter set in config null
26/03/25 11:11:39 INFO output.FileOutputCommitter: File Output Committer Algorithm version is 1
26/03/25 11:11:39 INFO mapred.LocalJobRunner: OutputCommitter is org.apache.hadoop.mapreduce.lib.output.FileOutputCommitter
26/03/25 11:11:39 INFO mapred.LocalJobRunner: Waiting for map tasks
26/03/25 11:11:39 INFO mapred.LocalJobRunner: Starting task: attempt_local41287041_0001_m_000000_0
26/03/25 11:11:39 INFO output.FileOutputCommitter: File Output Committer Algorithm version is 1
26/03/25 11:11:39 INFO mapred.Task: Using ResourceCalculatorProcessTree : [ ]
26/03/25 11:11:39 INFO mapred.MapTask: Processing split: hdfs://localhost:9000/i
```

Les Opérations Hadoop

8. Vérifiez le contenu du fichier de sortie généré

Affichez les résultats du comptage des mots après l'exécution du job MapReduce.

```
hadoop fs -cat /output_dir/*
```



```
mohammed@ROG-Strix:~/HADOOP_REPO
) hadoop fs -cat /output_dir/part-r-00000

23      12
24       6
25      18
26      36
27      12
28      24
29       6
30      24
31      24
32      18
33       6
34      30
35       6
36      12
38      24
39      66
40      18
41      24
42       6
43      12
45       6

HADOOP_REPO )
```


Conclusion

Ce TP nous a permis de réaliser un projet WordCount complet avec Hadoop et MapReduce, depuis la préparation des données jusqu'à l'observation des résultats. Nous avons ainsi compris les principes essentiels du traitement distribué, la répartition des tâches entre les nœuds et le rôle central de Hadoop dans l'analyse de grands volumes de données. Cette expérience montre l'importance de maîtriser les concepts de calcul distribué dans les environnements Big Data. Elle constitue enfin une base solide pour approfondir l'étude de Hadoop et explorer d'autres applications MapReduce.