جامعة ابن طفيل
Ibn Tofaïl University

Travaux Pratiques 5 : Apache Spark - Traitement et Analyse Distribuée de Données Massives

---

Université / École :

- Université Ibn Tofail, Kénitra

Encadrement pédagogique :

- Pr. Hajar Filali

Rédigé par :

- Mohammed Jebrou
- Hajar Farid

Année universitaire :

- 2025–2026

Contexte, Objectifs et Compétences Visées

1. Intoduction

Ce TP a pour objectif de découvrir **Apache Spark**, un framework de traitement distribué largement utilisé dans les environnements Big Data. Face à l'augmentation continue du volume des données, Spark offre des solutions performantes pour le traitement, l'analyse et l'exploitation de données à grande échelle. À travers cette séance, nous explorerons ses principaux concepts et mettrons en pratique ses fonctionnalités essentielles.

2. Objectif

L'objectif de ce TP est de prendre en main l'environnement Apache Spark en réalisant son installation et sa configuration, puis de découvrir les opérations de base de traitement de données à l'aide du Spark Shell. À travers des exercices simples de manipulation de collections et de filtrage de données, ce TP permet de se familiariser avec les concepts fondamentaux de Spark et avec l'utilisation des RDDs pour le traitement distribué des données.

Étape 1 : téléchargement des indpendance

1. Installation de Java (JDK)

- Java est déjà installé

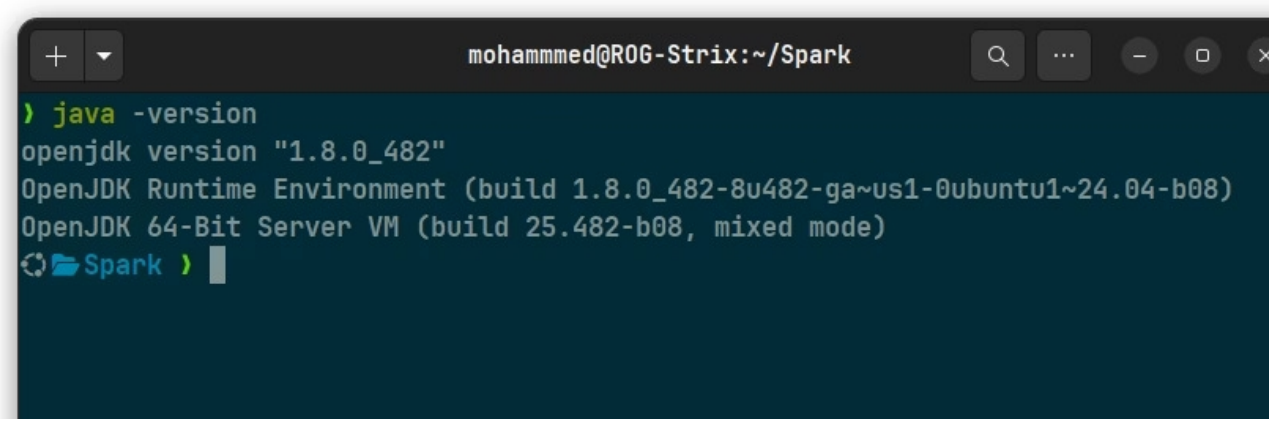

2. Télechargement du dossier d'Apache Spark

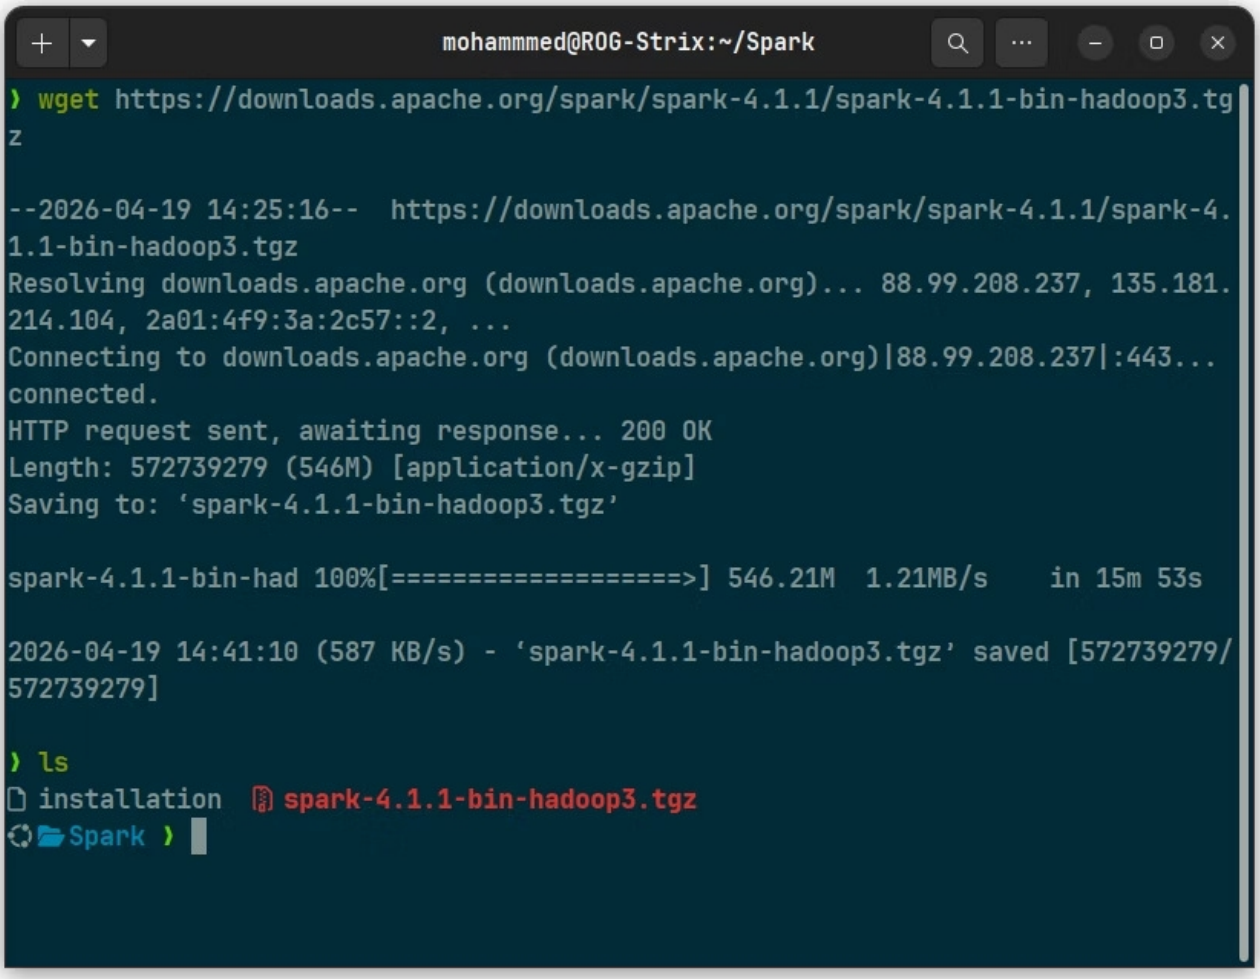

Étape 2: Configuration des Variables d'Environnement

1. Extraction du dossier

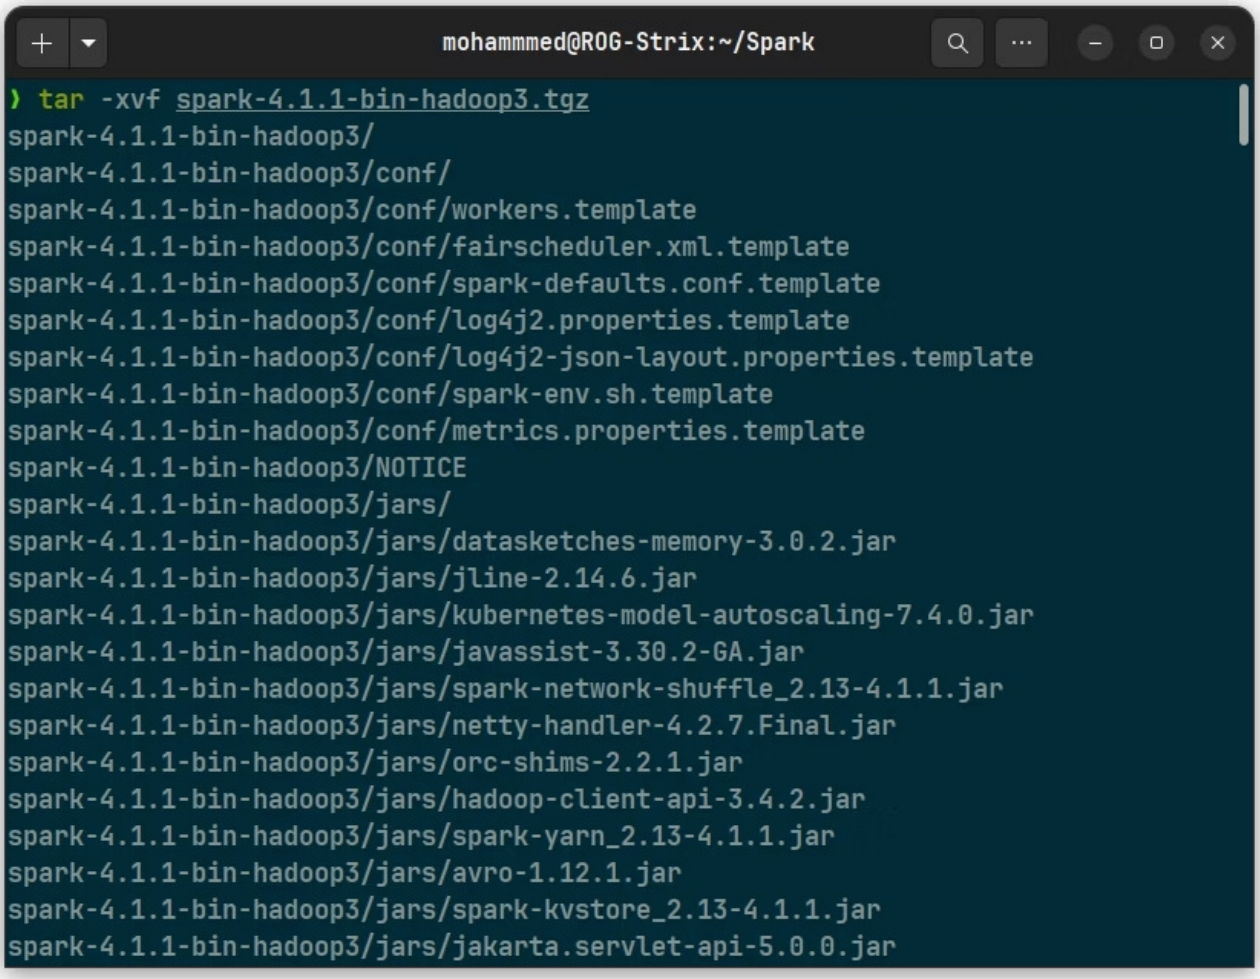

2. Déplacement du Spark vers `~/`

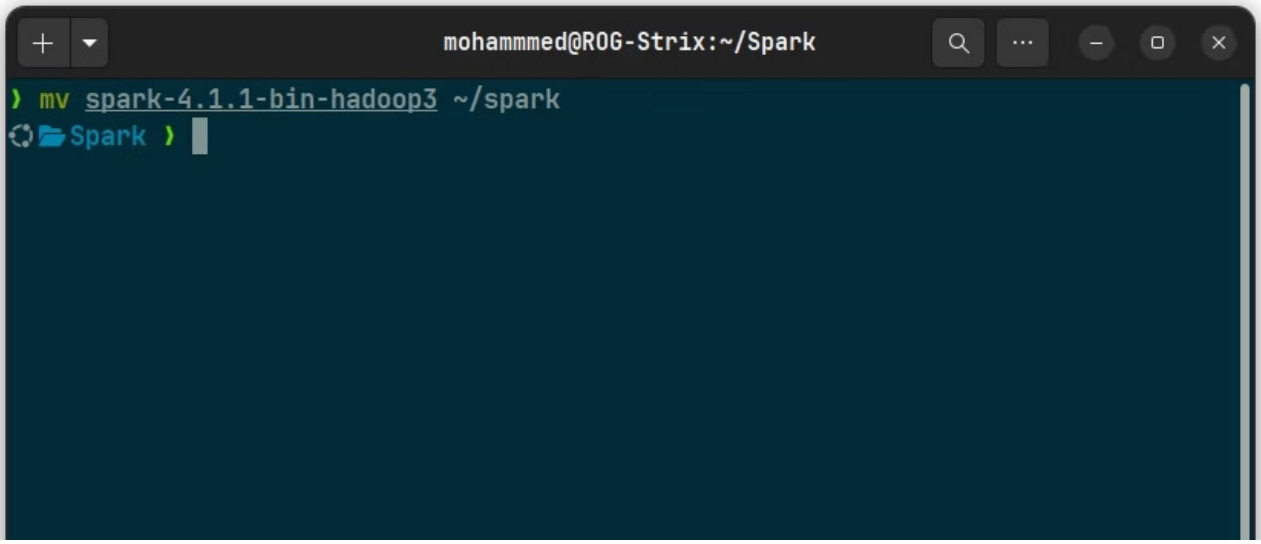

3. Définition des variables d'environnement

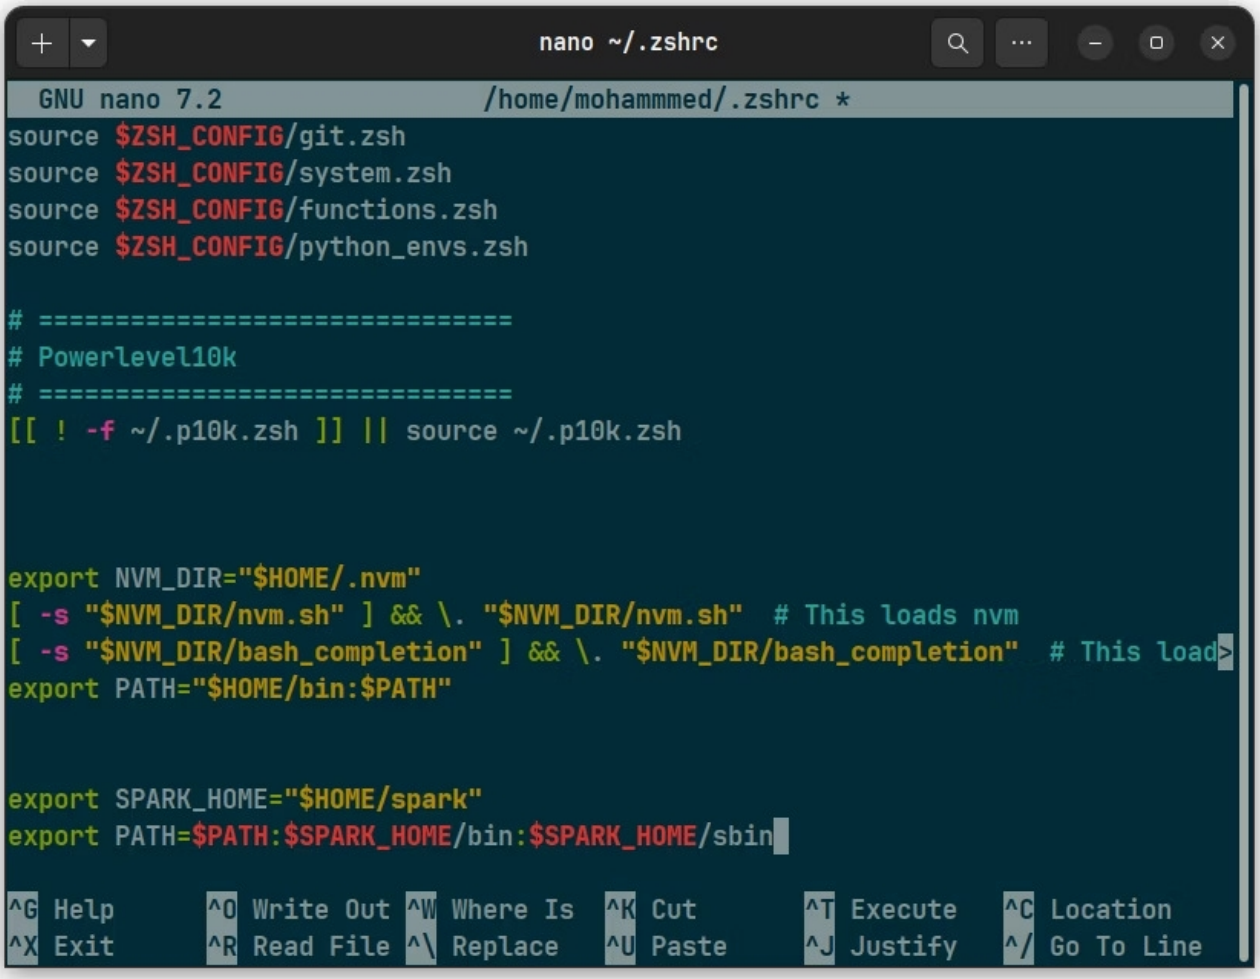

4. Application des modifications

Après l'ajout des variables d'environnement de Spark dans le fichier ~/.zshrc, il est nécessaire de recharger la configuration du shell afin que les changements soient pris en compte.

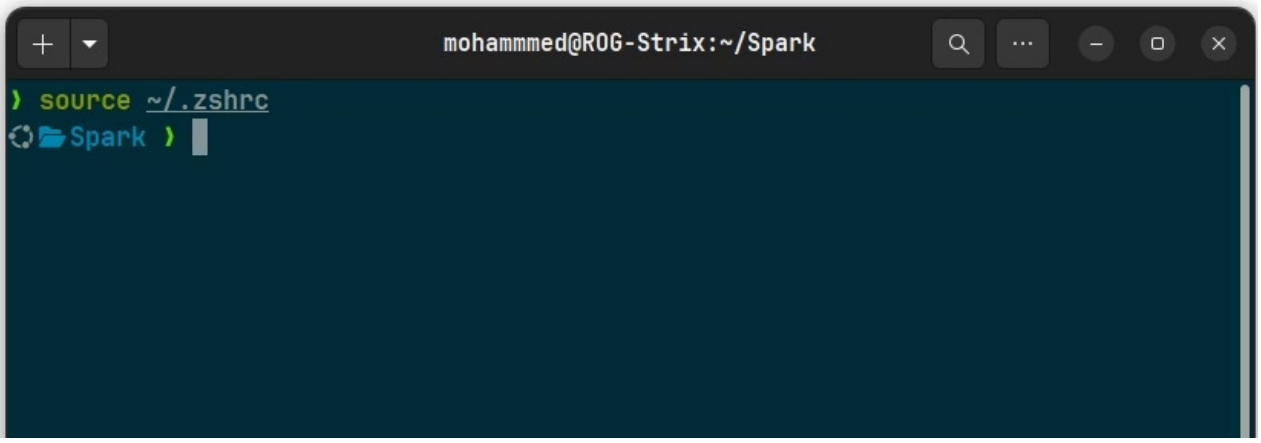

Étape 3: Vérification et lancement

1. Lancement du Spark-Shell

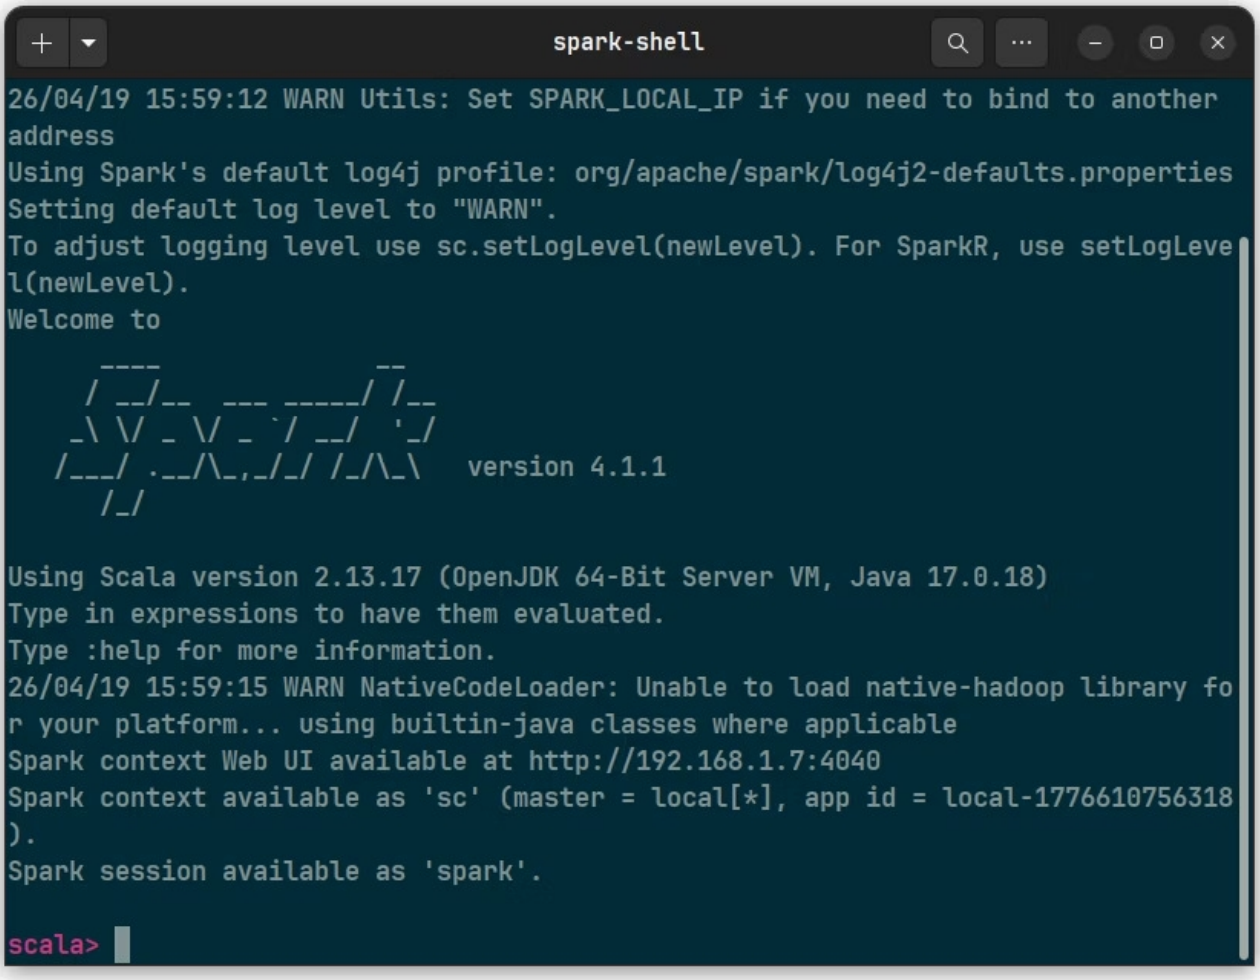

2. Vérification

Afin de vérifier que l'installation et la configuration de Spark ont été réalisées avec succès, une commande simple est exécutée dans le Spark Shell. L'affichage du message confirme que l'environnement Spark est opérationnel

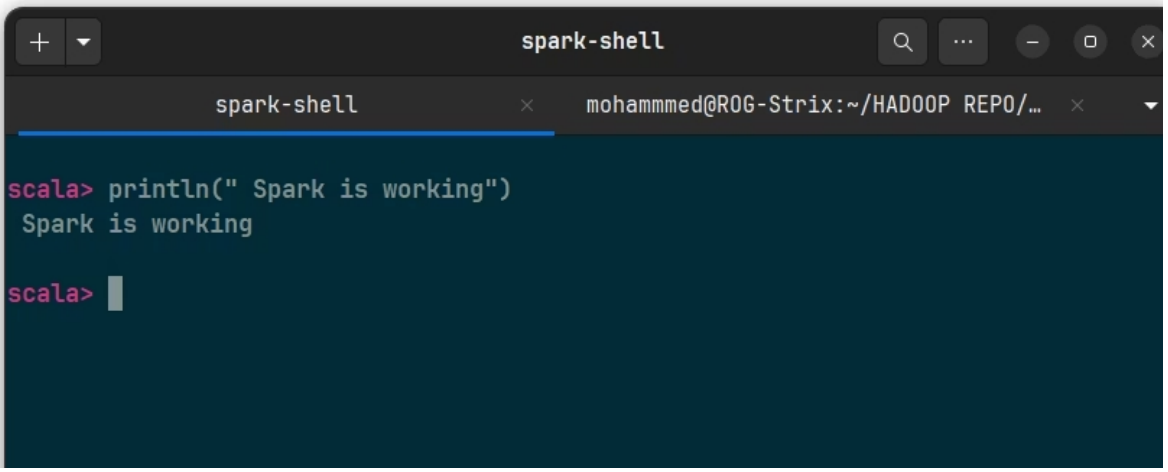

Exercices Pratiques : Opérations de Traitement de Données avec Apache Spark

1. Extraction des mots contient la lettre "a"

Cette opération utilise la méthode `filter()` afin de sélectionner les éléments contenant le caractère "a".

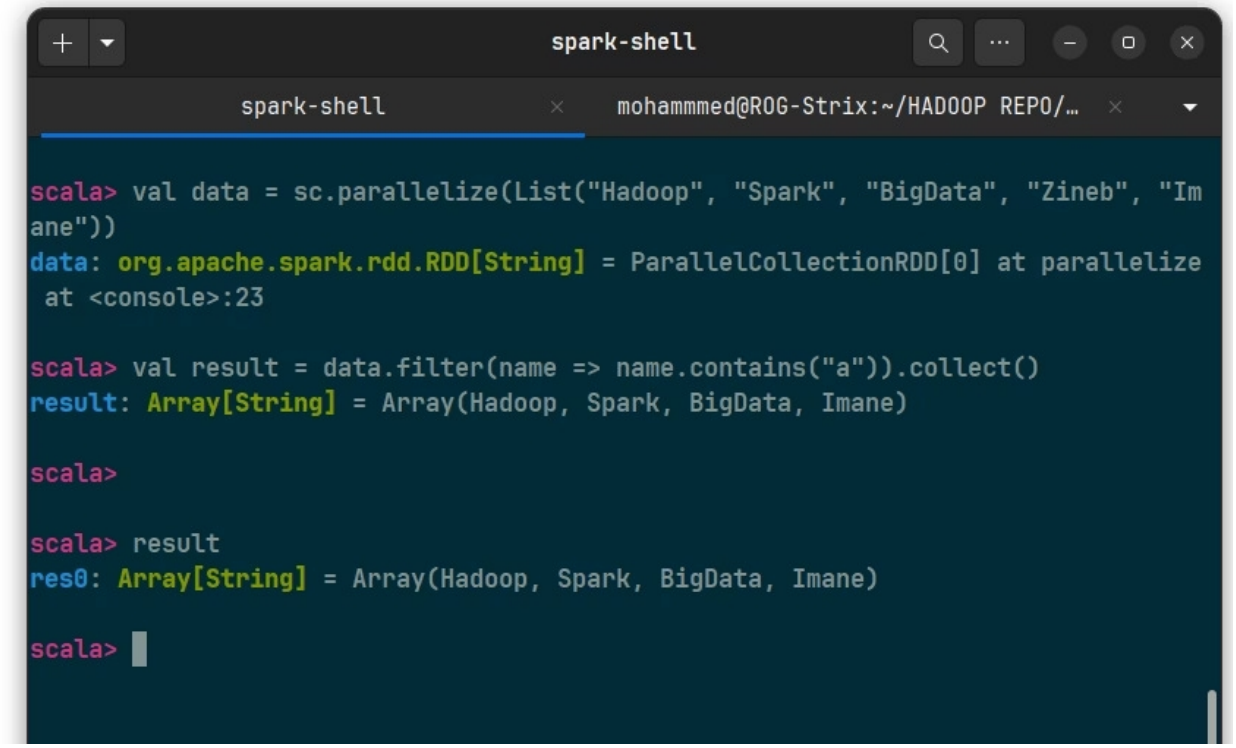

2. Extraction des mots commençant par la lettre « S »