



جامعة ابن طفيل
+ⵓⵔⵓⵏⵉⵙⵉⵔ ⵉⵎ ⵉⵔⵉⵎⵉⵏ
Ibn Tofaïl University



Apache Pig

Framework de Traitement de Données
à Grande Échelle

ENCADRE PAR:

Professeur Hajar El Filali

Présenté par:

Oumayma Hassine
Bassma Karroum



»»»» Sommaire

- | | | | |
|----|---------------------------|----|---|
| 01 | • Introduction | 07 | • pig vs mapreduce |
| 02 | • Définition | 08 | • Conclusion |
| 03 | • Architecture Générale | 09 | • Objectif du TP |
| 04 | • Cas d'Utilisation Réels | 10 | • Installation et Configuration |
| 05 | • Avantages et Limites | 11 | • Résolution d'erreurs et Validation du |
| 06 | • Cas Pratique | | Système |



Introduction

Qu'est-ce qu'Apache Pig ?

- Plateforme open-source développée par Yahoo! en 2006, devenue projet Apache en 2007
- Outil d'analyse de données massive permettant de traiter des volumes de données considérables (Big Data)
- S'exécute sur Hadoop (HDFS et MapReduce) ou d'autres moteurs comme Tez et Spark

Pourquoi Pig ?

- Nom inspiré de la capacité du cochon à "manger n'importe quoi" → Pig peut ingérer n'importe quel type de données


▶ Définition

Apache Pig est une plateforme d'analyse de données volumineuses basée sur Hadoop. Il utilise un langage de haut niveau appelé Pig Latin, qui est ensuite traduit automatiquement en tâches MapReduce exécutées sur un cluster Hadoop.

Caractéristiques clés :

- Schémas définis à l'exécution, pas à la compilation
- Orienté pipeline (flux de données entre opérations)
- Abstraction de MapReduce/Spark

► Architecture Générale d'Apache Pig



Apache Pig repose sur une architecture en quatre couches distinctes, chacune jouant un rôle précis dans la transformation d'un script Pig Latin en jobs distribués exécutés sur le cluster



► Cas d'Utilisation Réels

- **ETL :** Utilisé par Yahoo! et Facebook pour traiter des logs web massifs.
 - **ANALYSE DE LOGS:** Traitement de lignes de journaux serveur en mode batch distribué
 - **RECOMMANDATION :** Traitement de données comportementales
 - **DATA WAREHOUSE:** Alimentation de pipelines d'entreprise.
- 



Avantages et Limites

✓ AVANTAGES

- Syntaxe simple
- Gère données structurées et non-structurées
- pas de java
- Extensible via UDF (Python, Java)

✗ LIMITES

- Pas adapté au temps réel
- Moins performant que Spark
- Communauté en déclin



Cas Pratique

Objectif : calculer le chiffre d'affaires total par région depuis un fichier CSV.

```
ventes = LOAD '/data/ventes.csv' USING PigStorage(',')
        AS (produit:chararray, region:chararray, montant:float);

ventes_clean = FILTER ventes BY montant > 0;

ventes_grouped = GROUP ventes_clean BY region;

ca_par_region = FOREACH ventes_grouped GENERATE
                group AS region,
                SUM(ventes_clean.montant) AS total_ca;

STORE ca_par_region INTO '/output/ca_par_region';
```

RÉSULTAT :

```
Casablanca, 12500000.0
Rabat, 9800000.0
Marrakech, 7200000.0
```


▶ pig vs mapreduce




- traitement de données de haut niveau
- Scripts simples
- Opérations intégrées
- support des données imbriquées



- traitement de données de bas niveau
- Programmes Java complexes
- Traitement difficile
- Pas de données imbriquées

► Conclusion

Apache PIG a simplifié l'accès au Big Data en permettant de traiter des données massives sans maîtriser Java. Aujourd'hui remplacé progressivement par Apache Spark, il reste une référence importante pour comprendre les fondamentaux du traitement distribué sur Hadoop.



TP: Installation et Configuration d'Apache Pig sur Windows

► Objectif

Ce rapport détaille les étapes nécessaires pour installer et configurer Apache Pig (version 0.17.0) dans un environnement Windows, en surmontant les erreurs courantes liées aux variables d'environnement et à l'intégration avec Hadoop.



Prérequis

- Java JRE/JDK installé (de préférence version 8 ou 11).
- Hadoop installé (optionnel, uniquement pour le mode MapReduce).



▶ étape 1 : Prérequis et Installation des Composants

- Rendez-vous sur le site officiel des archives Apache :


<https://archive.apache.org/dist/pig/pig-0.17.0/pig-0.17.0.tar.gz>

1. Téléchargement : Extraire l'archive d'Apache Pig dans C:\pig-0.17.0.
2. Vérification de la structure : S'assurer que le dossier bin se trouve directement sous le chemin spécifié.

► étape 2 : Configuration des Variables d'Environnement

C'est l'étape la plus critique pour que Windows reconnaisse les commandes Pig

- PIG_HOME : Créer une variable système pointant vers [C:\pig-0.17.0](#).




Modifier la variable utilisateur

Nom de la variable : PIG_HOME

Valeur de la variable : C:\pig-0.17.0

Parcourir le répertoire.. Parcourir le fichier... OK Annuler

- Path : Ajouter [C:\pig-0.17.0\bin](#) à la variable système



C:\Java\jdk1.8.0_211\bin	Nouveau
C:\pig-0.17.0\bin	Modifier
%SystemRoot%\system32	Parcourir...
%SystemRoot%	Supprimer
%SystemRoot%\System32\Wbem	
%SYSTEMROOT%\System32\WindowsPowerShell\v1.0\	
%SYSTEMROOT%\System32\OpenSSH\	
C:\hadoop-2.7.0\bin	

▶ étape 3 : Résolution des Erreurs de Script (pig.cmd)

```
C:\Users\Administrateur>pig -version
Le chemin d'accès spécifié est introuvable.
'-Xmx1000M' n'est pas reconnu en tant que commande interne
ou externe, un programme exécutable ou un fichier de commandes.
```

- Erreur de localisation Java

#Forcer le chemin en ajoutant au début du fichier#

```
set JAVA_HOME=C:\Java\jdk1.8.0_211
set JAVA=%JAVA_HOME%\bin\java.exe
```

- Erreur d'allocation mémoire (1000M)

#Remplacer la ligne de configuration de la mémoire par #

```
set JAVA_HEAP_MAX=-Xmx512M
```

- Erreur d'allocation mémoire (1000M)

#Ajouter des guillemets "" à la commande finale call #

```
set JAVA_HEAP_MAX=-Xmx512Mcall "%JAVA%" %JAVA_HEAP_MAX% %PIG_OPTS%
-classpath "%CLASSPATH%" org.apache.pig.Main %PIGARGS%
```


▶ étape 4: Intégration avec Hadoop

Pig dépend des utilitaires natifs de Hadoop pour fonctionner sur Windows.

```
C:\Users\Administrateur>pig -version
avr. 22, 2026 1:48:11 AM org.apache.pig.impl.util.LogUtils writeLog
GRAVE: ERROR 2998: Unhandled internal error. org/apache/commons/collections/map/UnmodifiableMap
avr. 22, 2026 1:48:12 AM org.apache.pig.impl.util.LogUtils writeLog
AVERTISSEMENT: There is no log file to write to.
avr. 22, 2026 1:48:12 AM org.apache.pig.impl.util.LogUtils writeLog
GRAVE: java.lang.NoClassDefFoundError: org/apache/commons/collections/map/UnmodifiableMap
    at org.apache.hadoop.conf.Configuration$DeprecationContext.<init>(Configuration.java:408)
    at org.apache.hadoop.conf.Configuration.<clinit>(Configuration.java:448)
    at org.apache.pig.Main.run(Main.java:189)
    at org.apache.pig.Main.main(Main.java:175)
Caused by: java.lang.ClassNotFoundException: org.apache.commons.collections.map.UnmodifiableMap
    at java.net.URLClassLoader.findClass(URLClassLoader.java:382)
    at java.lang.ClassLoader.loadClass(ClassLoader.java:424)
    at sun.misc.Launcher$AppClassLoader.loadClass(Launcher.java:349)
    at java.lang.ClassLoader.loadClass(ClassLoader.java:357)
    ... 4 more

avr. 22, 2026 1:48:12 AM org.apache.pig.Main printScriptRunTime
INFOS: Pig script completed in 141 milliseconds (141 ms)
```

En cas d'absence de classes , copier les fichiers JAR nécessaires depuis [hadoop/common/lib](http://hadoop.common/lib) vers le dossier pig/lib.



Téléchargement	asm-3.2	10/04/2015 20:51	Executable Jar File	43 Ko
Documents	avro-1.7.4	10/04/2015 20:51	Executable Jar File	297 Ko
Images	commons-beanutils-1.7.0	10/04/2015 20:51	Executable Jar File	185 Ko
Musique	commons-beanutils-core-1.8.0	10/04/2015 20:51	Executable Jar File	202 Ko
Vidéos	commons-cli-1.2	10/04/2015 20:51	Executable Jar File	41 Ko
htdocs	commons-codec-1.4	10/04/2015 20:51	Executable Jar File	57 Ko
to1 big data	commons-collections-3.2.1	10/04/2015 20:51	Executable Jar File	562 Ko

▶ étape 5 : Vérification de l'Installation

- Pour confirmer que l'installation est réussie, exécutez la commande suivante dans un nouveau terminal :

pig -version

Résultat attendu : Le terminal doit afficher Apache Pig version 0.17.0.


```
C:\Users\Administrateur>pig -version
log4j:WARN No appenders could be found for logger (org.apache.hadoop.util.Shell).
log4j:WARN Please initialize the log4j system properly.
log4j:WARN See http://logging.apache.org/log4j/1.2/faq.html#noconfig for more info.
Apache Pig version 0.17.0 (r1797386)
compiled Jun 02 2017, 15:41:58
```

- Pour tester le mode local, utilisez :


pig -x local

```
C:\Users\Administrateur>pig -x local
log4j:WARN No appenders could be found for logger (org.apache.hadoop.util.Shell).
log4j:WARN Please initialize the log4j system properly.
log4j:WARN See http://logging.apache.org/log4j/1.2/faq.html#noconfig for more info.
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/C:/pig-0.17.0/lib/slf4j-log4j12-1.7.10%20-%20Copie.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/C:/pig-0.17.0/lib/slf4j-log4j12-1.7.10.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory]
```

Une fois l'invite `grunt>` affichée, le système est prêt pour le traitement de données.



conclusion



L'installation de Pig sur Windows nécessite une attention particulière à la gestion des **Classpaths** et des scripts de commande .cmd. Une fois ces configurations effectuées, Pig peut interagir efficacement avec Hadoop pour le traitement de Big Data.

MERCI

